

Dokumentacja Specyfikacji Wymagań (SRS)

Analiza i klasyfikacja orientacji politycznej przemówień State of Union
prezydentów USA w latach 1932-2026 na bazie obecnych dyskursów

Autorzy: Kacper Fedde, Antoni Piotrowski, Oskar Chamela

Data: 04.06.2026

Spis Treści

1	Wprowadzenie	2
2	Cele systemu	2
3	Wymagania funkcjonalne	2
3.1	Pozyskiwanie i wstępne przetwarzanie danych	2
3.2	Przetwarzanie języka naturalnego	2
3.3	Modelowanie i klasyfikacja (Uczenie Maszynowe)	2
3.4	Analiza wyników i wizualizacja	3
4	Wymagania niefunkcjonalne	3
4.1	Wydajność i optymalizacja zasobów	3
4.2	Kompatybilność	3
4.3	Niezawodność i powtarzalność	3
4.4	Użyteczność	3
4.5	Bezpieczeństwo danych	3
5	Interfejsy użytkownika i wymagania dotyczące danych	4
5.1	Interfejsy użytkownika	4
5.2	Wymagania dotyczące danych wejściowych	4
5.3	Charakterystyka danych wyjściowych	4
6	Słownictwo dokumentacji	4
7	Przypadki użycia (use cases)	5
7.1	Zasilanie bazy danych i wyodrębnienie treści	5
7.2	Przygotowanie danych i wektoryzacja	5
7.3	Modelowanie i eksploracja wyników	5
7.4	Sytuacje wyjątkowe i obsługa błędów	6
8	Scenariusze użytkownika (User Stories)	6

1 Wprowadzenie

W naszym projekcie chcemy przeanalizować wypowiedzi polityków - konkretnie prezydentów Stanów Zjednoczonych pod kątem poglądów politycznych i ocenić czy skłaniają się oni w prawą czy lewą stronę spektrum politycznego. W naszym programie wykorzystujemy algorytmy TF-IDF, klasyfikację, uczenie maszynowe oraz analizę sentymentów. System jest trenowany na danych pochodzących ze współczesnej prasy, której orientację polityczną można łatwo określić oraz na wybranych przemówieniach z badanego okresu. System jest stworzony do analizy tekstów w języku angielskim. Niniejszy dokument opisuje specyfikację wymagań dla załączonego skryptu w R.

2 Cele systemu

Program pobiera dane wejściowe w tabeli .xlsx, a następnie kategoryzuje je ze względu na poglądy polityczne mówcy, identyfikując trendy i sentyment wypowiedzi. Obok wybranych przemówień jako bazę do nauki naszego algorytmu wykorzystujemy artykuły autorstwa przedstawicieli partii republikańskiej i demokratycznej kolejno (CNN, Fox News). Cel naszej analizy jest dwójaki: badanie czy współcześni (tj. po 1932 roku) prezydenci w swoich wystąpieniach wykazują sentyment charakterystyczny dla ich partii oraz zbadanie jak, w obliczu zmieniających się sentymentu i wrażliwości społecznej, ocenianie są archiwalne wypowiedzi prezydentów z okresu wcześniejszego (tj. od 1789 roku).

3 Wymagania funkcjonalne

3.1 Pozyskiwanie i wstępne przetwarzanie danych

- Skrypt musi umożliwiać wczytanie przemówień z plików .xlsx.
- Skrypt musi umożliwiać pobranie tekstów treningowych z portali internetowych.
- System powinien weryfikować spójność zbioru danych, usuwając puste rekordy, powielone dokumenty oraz metadane zakłócające analizę.
- Skrypt musi ujednolicać kodowanie znaków do UTF-8.

3.2 Przetwarzanie języka naturalnego

- Narzędzie powinno przeprowadzać normalizację tekstu, tokenizację oraz stemming.
- Narzędzie musi filtrować tekst ze słów funkcyjnych, uwzględniając możliwość dodania własnej listy słów wykluczonych.

3.3 Modelowanie i klasyfikacja (Uczenie Maszynowe)

- Skrypt powinien konwertować oczyszczone teksty do reprezentacji wektorowej (przy użyciu macierzy TF-IDF).
- Narzędzie musi umożliwiać podział zbioru treningowego na zbiór uczący i testowy oraz trenowanie modelu klasyfikatora binarnego.
- System powinien oceniać skuteczność wytrenowanego modelu za pomocą metryk klasyfikacji.
- Skrypt musi aplikować wytrenowany model na zaimportowanych tekstach w celu przypisania im etykiety (demokratyczne/republikańskie).

3.4 Analiza wyników i wizualizacja

- System powinien zwracać chronologiczny zestaw wypowiedzi razem z przypisanymi autorami i przyporządkowanymi przewidywanymi poglądami politycznymi.
- Skrypt musi generować wykresy i chmury słów, charakterystyczne dla klasyfikacji TF-IDF.
- Narzędzie powinno identyfikować i prezentować w formie tabel i chmur słów cechy, które miały największy wpływ na decyzje modelu dla każdej z klas (prawicowe/lewicowe).
- System zwraca wizualizację metryk klasyfikacji, by użytkownik mógł określić, czy odpowiada mu otrzymana precyzja.

4 Wymagania niefunkcjonalne

4.1 Wydajność i optymalizacja zasobów

- Skrypt musi charakteryzować się wysoką wydajnością, umożliwiając szybką analizę i przetwarzanie dużych korpusów tekstowych.
- Implementacja powinna optymalizować zużycie pamięci operacyjnej (RAM), co zapewni stabilne działanie na standardowych stacjach roboczych bez wyczerpania zasobów.

4.2 Kompatybilność

- Rozwiązanie musi być w pełni kompatybilne ze środowiskiem R w wersji 4.0.
- Skrypt powinien opierać się na sprawdzonych i stabilnych pakietach R dedykowanych do analizy NLP i uczenia maszynowego. Wymagane jest wykorzystanie m.in. bibliotek takich jak `tidytext` lub `tm` (do przetwarzania tekstu), `e1071` (do klasyfikacji ML) oraz `ggplot2` lub `Wordcloud` (do wizualizacji wyników).

4.3 Niezawodność i powtarzalność

- Proces uczenia maszynowego musi być deterministyczny i w pełni odtwarzalny. Skrypt powinien gwarantować te same lub zbliżone wyniki predykcji przy każdym uruchomieniu.
- System musi być odporny na braki lub anomalie w danych historycznych.

4.4 Użyteczność

- Kod musi wspierać podejście reproducible research, czyli powinien być on stworzony w formacie możliwym do powtórzenia czy odtworzenia.
- Skrypt z kodem powinien być czytelnie napisany w podziale na sekcję z obecnymi komentarzami.
- Generowane wykresy i chmury słów muszą być czytelne, wyposażone w opisane osie, tytuły, legendy.
- W przypadku generowania raportu końcowego (np. przy użyciu R Markdown), dokument musi posiadać przejrzystą strukturę z podziałem na sekcje.

4.5 Bezpieczeństwo danych

- Całkowite przetwarzanie danych, trenowanie modelu ML oraz klasyfikacja tekstów musi odbywać się lokalnie na maszynie badacza.

5 Interfejsy użytkownika i wymagania dotyczące danych

5.1 Interfejsy użytkownika

Z uwagi na badawczo-analityczny charakter projektu, oprogramowanie nie posiada klasycznego graficznego interfejsu użytkownika.

- Cała interakcja z systemem odbywa się z poziomu zintegrowanego środowiska programistycznego (np. RStudio lub pokrewne).
- Użytkownik zarządza przepływem danych poprzez uruchamianie dedykowanych skryptów analitycznych bezpośrednio w konsoli.
- Konfiguracja parametrów wejściowych realizowana jest z poziomu kodu źródłowego.

5.2 Wymagania dotyczące danych wejściowych

System przetwarza dwa niezależne strumienie danych wejściowych, co wymusza dostęp do lokalnego systemu plików oraz aktywnego połączenia sieciowego.

- Dane ewaluacyjne stanowi zbiór historycznych orędzi State of the Union wczytywany jest z ustrukturyzowanego pliku arkusza kalkulacyjnego w formacie `.xlsx`.
- Dane treningowe tworzy zbiór tekstów o zdefiniowanym profilu prawicowym i lewicowym jest pozyskiwany dynamicznie metodą *web scrapingu*. Skrypt automatycznie pobiera surowy tekst ze zdefiniowanych adresów URL.

5.3 Charakterystyka danych wyjściowych

Wynikiem działania skryptów są:

- Raport HTML: Głównym punktem wyjścia jest kompleksowy raport w formacie `.html`, agregujący cały przebieg badania.
- Wizualizacje graficzne: System eksportuje gotowe wykresy oraz chmury słów charakterystyczne dla obu sentymentów oraz tabele z klasyfikacją konkretnych wypowiedzi.

6 Słownictwo dokumentacji

- **Web Scraping** – technika zautomatyzowanego pobierania i ekstrakcji nieustrukturyzowanych informacji bezpośrednio ze stron internetowych
- **Korpus** – ustrukturyzowany i ujednolicony zbiór dokumentów tekstowych, stanowiący podstawę do analiz statystycznych oraz trenowania modeli.
- **Chmura słów** – metoda wizualizacji danych tekstowych, w której wielkość czcionki danego tokenu jest wprost proporcjonalna do jego wagi w analizowanym korpusie.
- **Asocjacje** – konotacje między słowami mierzone np.: współczynnikiem korelacji.
- **TF-IDF (Term Frequency - Inverse Document Frequency)** – statystyczna miara oceniająca wagę słowa w dokumencie w kontekście całego korpusu. Metoda ta zwiększa wagę słów częstych w danym tekście, a jednocześnie obniża wagę słów pospolitych występujących w większości dokumentów.
- **Klasyfikacja** – zadanie predykcyjne z zakresu eksploracji danych, polegające na przyporządkowaniu wejściowego obiektu (np. nieznanego przemówienia) do jednej ze z góry zdefiniowanych, dyskretnych kategorii (np. dyskurs prawicowy / lewicowy).

- **Uczenie maszynowe nadzorowane** – paradygmat tworzenia modeli sztucznej inteligencji, w którym algorytm uczy się wzorców na podstawie tzw. danych treningowych, gdzie każda obserwacja posiada z góry przypisaną, prawidłową etykietę.
- **Macierz pomyłek** – tabelaryczne zestawienie stosowane do oceny skuteczności modelu klasyfikacyjnego. Porównuje rzeczywiste przynależności klasowe obiektów z predykcjami wygenerowanymi przez model.
- **Metryki klasyfikacji** – ilościowe wskaźniki oceniające wydajność wytrenowanego modelu, wyliczane na podstawie macierzy pomyłek. Do najważniejszych należą:
 - **Accuracy**: stosunek poprawnych klasyfikacji do wszystkich przypadków.
 - **Precision**: stosunek poprawnie przewidzianych przypadków pozytywnych do wszystkich przypadków zidentyfikowanych przez model jako pozytywne
 - **Recall**: stosunek poprawnie przewidzianych przypadków pozytywnych do wszystkich rzeczywistych przypadków z tej klasy.
 - **F1-Score**: średnia harmoniczna precision i recall.

7 Przypadki użycia (use cases)

Rozdział ten opisuje interakcję użytkownika z systemem:

7.1 Zasilanie bazy danych i wyodrębnienie treści

Użytkownik inicjuje potok danych, przekazując do systemu listę docelowych adresów URL, reprezentujących teksty o wyraźnym profilu prawicowym i lewicowym. W scenariuszu budowy bazy treningowej, system łączy się ze wskazanymi witrynami i ekstrahuje zawartość tekstową. Program odcina od właściwej treści elementy zbędne, po czym zapisuje oczyszczony tekst jako zbiór danych treningowych. Równolegle użytkownik wskazuje ścieżkę do lokalnego pliku .xlsx, w którym zgromadzono historyczne przemówienia prezydentów.

7.2 Przygotowanie danych i wektoryzacja

Po zgromadzeniu surowych dokumentów, proces przechodzi do fazy oczyszczania i wektoryzacji tekstu. System automatycznie pobiera korpus roboczy, unifikuje wielkość liter oraz eliminuje interpunkcję, cyfry i znaki specjalne. Następnie realizowane są stemming i tokenizacja oraz redukcja najczęściej występujących słów pozbawionych wartości analitycznej. Kluczowym punktem zwrotnym tej fazy jest transformacja oczyszczonego tekstu naturalnego do postaci liczbowej. System oblicza wagi TF-IDF.

7.3 Modelowanie i eksploracja wyników

Po sparametryzowaniu macierzy TF-IDF, uruchamiane są algorytmy - analizy sentymentu, optymalizacji i uczenia maszynowego (SVM) i dopasowywania wektora słów pliku tekstowego do zbioru treningowego. System, wykorzystując zbiór uczący zebrany ze stron internetowych, trenuje klasyfikator binarny. W kolejnym kroku model aplikowany jest na historycznych orędziach prezydentów USA. Po zakończeniu predykcji, system agreguje wyniki i generuje: chmury słów, wykresy trendów, tabele wyników. Użytkownik samodzielnie wykonuje (korzystając z R Markdown) raport HTML podsumowujący badanie.

7.4 Sytuacje wyjątkowe i obsługa błędów

Możliwe jest wystąpienie specyficznych zdarzeń brzegowych, które przerywają standardowe działanie systemu:

- **Błąd pobierania danych:** W przypadku niedostępności serwera źródłowego lub wdrożenia mechanizmów anti-scrapingowych na podanych adresach URL, system zgłasza wyjątek na poziomie konsoli R i przerywa proces uczenia.
- **Nieprawidłowy format wejścia:** Jeśli załadowany plik .xlsx nie posiada zakładanej struktury, skrypt wyrzuca błąd parsowania przed rozpoczęciem fazy wektoryzacji.
- **Ograniczenia sprzętowe (Memory Limit):** Operowanie na potężnych korpusach bywa pamięciochłonne. Jeśli środowisko napotka ograniczenia pamięci skrypt zatrzymuje się.

8 Scenariusze użytkownika (User Stories)

Scenariusz 1: Ocena profilu ideologicznego nieznanego źródła

Jako: Badacz

Chcę: wczytać do programu samodzielnie zebrany plik z wypowiedziami politycznymi

Aby: zweryfikować, czy dane źródło skłania się ku poglądom prawicowym, czy lewicowym.

Kryteria akceptacji:

- Użytkownik skutecznie ładuje własny plik tekstowy z zebranymi wypowiedziami.
- System klasyfikuje dokumenty i zwraca zbiorczy, procentowy rozkład afiliacji ideologicznej całego źródła.

Scenariusz 2: Identyfikacja dominujących narracji w debacie

Jako: Obserwator dyskursu publicznego

Chcę: przepuścić przez klasyfikator transkrypt lub zbiór komentarzy z debaty publicznej

Aby: jednoznacznie stwierdzić, jakie narracje i kierunki polityczne dominują w tej dyskusji.

Kryteria akceptacji:

- Algorytm przetwarza podany transkrypt i zwraca klasyfikację podanych tekstów do afiliacji ideologicznej

Scenariusz 3: Weryfikacja populizmu i wierności partyjnej

Jako: Analityk polityczny

Chcę: przeanalizować zbiór wystąpień konkretnego polityka

Aby: sprawdzić, czy jego retoryka jest spójna z doktryną partii, czy populistycznie dopasowuje się do obecnych nastrojów.

Kryteria akceptacji:

- Skrypt wykrywa odchylenia od linii ideologicznej.

Scenariusz 4: Ewolucja historycznego dyskursu w świetle dzisiejszych standardów

Jako: Badacz historii politycznej

Chcę: sklasyfikować teksty historycznych debat przy użyciu modelu wytrenowanego wyłącznie na współczesnych danych sieciowych

Aby: zbadać ewolucję języka politycznego

Kryteria akceptacji:

- System skutecznie aplikuje model na chronologicznie uporządkowanym zbiorze tekstów historycznych i generuje tabele, które ukazują ewentualne przesunięcia dawnego dyskursu względem dzisiejszych standardów lewicy i prawicy.